生成 + 强化学习 + 多参数评分的工业界范式

关键：奖励的每一项都是真实目标的代理，
优化压力越大，越可能钻代理的漏洞。

