科研智能体的四类失效模式与对应防护

幻觉引用

编造不存在的文献、专利或实验结果

防护：强制检索增强：每条结论附可点击的原始链接

偏向主流

复述文献中说得最多的观点，强化已知偏差

防护：显式要求列出反面证据与争议

工具误用

调用了正确的工具但参数或解读错误

防护：工具输出做单位、量纲与范围的自动校验

级联错误

多步推理中早期错误被后续步骤放大

防护：每步设置可验证的中间检查点

共同原则：智能体的输出是“待核查的线索”，不是“已验证的结论”。