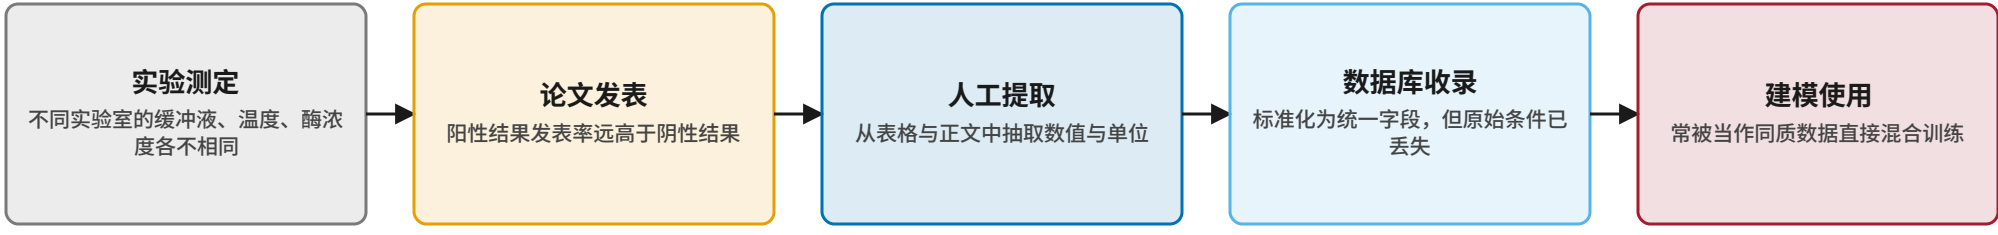
一个活性数据点的来龙去脉：每一步都可能引入误差



同一个分子对同一个靶点的 IC50，不同文献之间相差 10 倍并不罕见

这不是数据录入错误，而是实验条件差异的真实反映

对建模的含义： 训练标签本身带有约 0.5 个对数单位的固有噪声，模型精度不可能超过这个下限

对评测的含义： 测试集误差低于标签噪声，通常意味着数据泄漏而非模型优秀

对实践的含义： 跨来源混合数据时，应保留来源字段并检查同一分子的多次测定是否一致