# 药物研发数据中的六类系统性偏差

| | |
|---|---|
| **研究热点偏差** | 少数靶点占据绝大部分文献与数据<br>**后果：模型在冷门靶点上几乎没有可学的信号** |
| **发表偏差** | 阳性结果发表率远高于阴性结果<br>**后果：模型学到的是“什么有效”，而非“什么无效”** |
| **设计偏差** | 医药化学以系列形式探索，骨架高度聚集<br>**后果：随机划分会高估模型对新骨架的泛化能力** |
| **活性阈值偏差** | 弱活性与无活性常被记为“大于某值”<br>**后果：回归模型把截断值当作真实测量值** |
| **人群偏差** | 临床与组学数据以欧洲血统人群为主<br>**后果：遗传学证据在其他人群中的可迁移性未知** |
| **时间偏差** | 方法与标准随年代变化，老数据口径不同<br>**后果：跨年代混合训练会引入不可见的分布漂移** |

**六类偏差的共同点：它们都不是随机噪声，因此无法靠增大数据量抵消。**