读到一个性能数字时该问的七个问题

划分方式是什么？	随机、骨架、时间——三者评价的是不同能力
基线是什么？	与随机森林或最近邻比过吗，还是只与其他深度模型比
指标是否匹配用途？	排序任务用富集指标，不是全局相关系数
标签噪声是多少？	测试误差低于标签噪声就要怀疑泄漏
适用域覆盖了什么？	测试集与真实使用场景的分布是否一致
重复了几次？	单次运行的差异可能大于方法之间的差异
消融做了吗？	去掉关键输入后性能是否下降，若不降则模型学的是别的

七问中任何一问没有答案，这个数字就不足以支撑决策。