数据泄漏的五条路径：为什么基准分数会虚高

系列泄漏

同一篇论文的同系列类似物被随机分到训练集与测试集两边

对策：按骨架或来源文献划分

时间泄漏

用后来才有的数据训练，去预测更早的结果

对策：按时间划分，模拟真实的前瞻场景

结构泄漏

测试集的蛋白与训练集高度同源（序列相似度 > 30%）

对策：按序列相似度或家族聚类划分

预处理泄漏

标准化、特征选择或归一化在划分之前对全量数据做

对策：所有预处理只在训练折内拟合

调参泄漏

用测试集反复调超参，测试集实际上变成了验证集

对策：划出独立的、只用一次的保留集

五条路径的共同后果：报告的性能描述的是记忆能力，而不是泛化能力。